

DOCUMENTO DE REQUISITOS

Pipeline de Monitoramento de Preços de Combustíveis — ANP
Projeto de portfólio | Engenharia de Dados — nível Júnior

Versão	1.0	Data	Julho/2026
Status	Aprovado para desenvolvimento	Tipo	ELT batch — dados públicos

1. Objetivo do Projeto

Construir um pipeline de dados **end-to-end** que ingere a série histórica de preços de combustíveis da ANP (Agência Nacional do Petróleo, Gás Natural e Biocombustíveis), trata e modela os dados em camadas (Bronze / Silver / Gold) e disponibiliza análises em dashboard, respondendo às seguintes perguntas de negócio:

- **P1:** Como os preços de gasolina, etanol e diesel evoluíram por estado ao longo do tempo?
- **P2:** Em quais estados o etanol compensa frente à gasolina? (regra dos 70%: razão etanol/gasolina $\leq 0,70$)
- **P3:** Quais estados apresentaram as maiores variações percentuais de preço mês a mês?

2. Fonte de Dados

Item	Detalhe
Dataset	Série Histórica de Preços de Combustíveis — preços por posto revendedor (semanal)
Página oficial de download (CSVs)	https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-de-precos-de-combustiveis
Portal de Dados Abertos	https://dados.gov.br/dados/conjuntos-dados/serie-historica-de-precos-de-combustiveis-e-d-e-glp
Dicionário de dados (metadados)	https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/arquivos/shpc/metadados-serie-historica-precos-combustiveis.pdf
Formato	CSV, separador ponto e vírgula (;), encoding Latin-1 (ISO-8859-1), decimal com vírgula
Granularidade	1 linha = 1 coleta de preço em 1 posto, para 1 produto, em 1 data
Periodicidade dos arquivos	Semestrais (ex.: 2026-01 = 1º semestre de 2026); atualização semanal pela ANP
Volume estimado	~400 MB a 1 GB por semestre (combustíveis automotivos); milhões de linhas
Produtos	Gasolina C (comum e aditivada), Etanol hidratado, Diesel (S-10 e S-500), GNV, GLP P13
Licença	Dados abertos — Decreto nº 8.777/2016

Nota: os links acima podem mudar com reestruturações do portal gov.br. Em caso de link quebrado, buscar por “ANP série histórica de preços de combustíveis dados abertos”.

2.1 Principais colunas do CSV bruto

Coluna original	Tipo destino	Observação de tratamento
Regiao - Sigla	CHAR(2)	Padronizar maiúsculas
Estado - Sigla	CHAR(2)	Validar contra as 27 UFs
Municipio	VARCHAR	Corrigir encoding e acentuação
Revenda	VARCHAR	Nome do posto; normalizar espaços
CNPJ da Revenda	VARCHAR(18)	Manter máscara ou limpar para dígitos

Coluna original	Tipo destino	Observação de tratamento
Produto	VARCHAR	Padronizar categorias (ex.: GASOLINA, ETANOL)
Data da Coleta	DATE	Converter de DD/MM/AAAA
Valor de Venda	NUMERIC(6,3)	Trocar vírgula decimal por ponto
Valor de Compra	NUMERIC(6,3)	Alta taxa de nulos — manter como opcional
Unidade de Medida	VARCHAR	R\$/litro, R\$/m ³ (GNV), R\$/13kg (GLP)
Bandeira	VARCHAR	Distribuidora; tratar 'BRANCA' e nulos

3. Stack Tecnológica

Camada	Ferramenta / Versão	Função no projeto
Linguagem	Python 3.11+	Extração, limpeza e utilitários
Processamento	Polars (ou pandas)	Leitura e transformação dos CSVs grandes
Orquestração	Apache Airflow 2.9	DAG com agendamento e retries
Data Warehouse	PostgreSQL 16	Camadas Silver e Gold
Transformação SQL	dbt Core 1.8	Modelos staging → marts + testes
Qualidade de dados	dbt tests / Great Expectations	Validações automatizadas
Infraestrutura	Docker + Docker Compose	Ambiente reproduzível (Airflow, Postgres, Metabase)
Visualização	Metabase	Dashboards das perguntas P1–P3
Versionamento	Git + GitHub	Commits organizados (Conventional Commits)
CI	GitHub Actions	Lint (ruff) + testes (pytest) a cada push
Formato Bronze	Parquet (compressão snappy)	Dado bruto imutável e compacto

4. Arquitetura (Camadas Medallion)

ANP (CSV) --> BRONZE (Parquet, dado bruto imutável)
 --> SILVER (Postgres: limpo, tipado, deduplicado)
 --> GOLD (Postgres via dbt: star schema + agregações)
 --> DASHBOARD (Metabase)

Orquestração: Airflow executa Extract -> Load Bronze -> Transform Silver
 -> dbt run (Gold) -> dbt test, com carga incremental por semestre.

4.1 Modelagem Gold (star schema)

- **fato_precos:** sk_local, sk_tempo, sk_produto, preco_medio, preco_min, preco_max, desvio_padrao, qtd_postos
- **dim_local:** sk_local, uf, municipio, regioao
- **dim_produto:** sk_produto, nome_produto, unidade
- **dim_tempo:** sk_tempo, data, ano, mes, semestre
- **Marts analíticos:** precos_mensais_uf, razao_etanol_gasolina (flag compensa_etanol ≤ 0,70), variacao_mensal

5. Estrutura de Pastas do Repositório

```
anp-fuel-pipeline/
|-- dags/                # DAGs do Airflow
```

```

|   |-- anp_pipeline.py
|-- src/                               #Codigo Python
|   |-- extract.py                     #Download dos CSVs da ANP
|   |-- transform.py                   #Limpeza Bronze -> Silver
|   |-- load.py                        #Carga no Postgres
|   |-- utils/                         #Funcoes compartilhadas (log, config)
|-- dbt/                               #Projeto dbt
|   |-- models/
|       |-- staging/                   #Views sobre a Silver
|       |-- marts/                     #Tabelas Gold (fato, dims, analises)
|   |-- tests/                         #Testes customizados
|   |-- dbt_project.yml
|-- tests/                             #Testes unitarios (pytest)
|-- data/                              #Camada Bronze local (no .gitignore)
|   |-- bronze/
|-- docs/                              #Diagramas e prints do dashboard
|-- docker-compose.yml
|-- .env.example                       #Modelo de variaveis (nunca commitar .env)
|-- .gitignore
|-- requirements.txt
|-- README.md

```

6. Requisitos Funcionais

ID	Requisito	Critério de aceite
RF-01	Baixar os CSVs semestrais da ANP automaticamente	Arquivo salvo em data/bronze/ como Parquet, com log de execução
RF-02	Carga incremental	Reexecução não reprocessa semestres já carregados
RF-03	Limpeza e tipagem (Silver)	Encoding UTF-8, decimal com ponto, datas em DATE, duplicados removidos
RF-04	Modelagem dimensional (Gold)	Fato + 3 dimensões criadas via dbt, com documentação
RF-05	Análise P1 — evolução por UF	Gráfico de linha por UF/produto no dashboard
RF-06	Análise P2 — etanol vs gasolina	Tabela/mapa com razão e flag compensa_etanol
RF-07	Análise P3 — variação mensal	Ranking de variações % mês a mês por UF
RF-08	Pipeline orquestrado	DAG única executa todas as etapas com retries e alerta de falha

7. Requisitos Não Funcionais

ID	Requisito
RNF-01	Reprodutibilidade: projeto sobe com um único comando (docker compose up -d)
RNF-02	Segurança: credenciais somente em .env; .env no .gitignore; .env.example versionado
RNF-03	Performance: processamento de 1 semestre (~1 GB) em menos de 10 min em máquina local
RNF-04	Idempotência: reexecutar o pipeline não gera duplicados nas camadas Silver/Gold
RNF-05	Observabilidade: logs estruturados por etapa (início, fim, linhas processadas, erros)
RNF-06	Qualidade de código: lint (ruff) e testes (pytest) passando no CI
RNF-07	Documentação: README com arquitetura, como rodar, decisões técnicas e prints

8. Testes de Qualidade de Dados

Teste	Regra	Camada
not_null	valor_venda, uf, data_coleta e produto nunca nulos	Silver
accepted_values	UF pertence às 27 unidades federativas válidas	Silver
preco_positivo	valor_venda > 0	Silver
preco_range	valor_venda entre R\$ 1,00 e R\$ 15,00 (outliers)	Silver
unique	Chave composta (cnpj, produto, data_coleta) única	Silver
relationships	FKs da fato_precos existem nas dimensões	Gold
recência	Data máxima carregada dentro do semestre esperado	Gold

9. Fases de Execução (Roadmap)

Fase	Entrega	Estimativa
F1 — Setup	Repositório, Docker Compose (Postgres + Airflow + Metabase), .env	1 semana
F2 — Ingestão	extract.py + camada Bronze em Parquet + DAG básica	1 semana
F3 — Silver	Limpeza completa, carga no Postgres, testes pytest	1–2 semanas
F4 — Gold	Projeto dbt: staging, dims, fato, marts + dbt tests	1–2 semanas
F5 — Dashboard	Metabase com as análises P1, P2 e P3	1 semana
F6 — Acabamento	CI no GitHub Actions, README final, prints, revisão	1 semana

Estimativa total: 6 a 8 semanas em ritmo de estudo (5–8 h/semana).

10. Fora de Escopo (v1.0)

- Deploy em nuvem (BigQuery/AWS) — previsto como melhoria futura
- Dados em tempo real / streaming — o dataset é batch semanal por natureza
- Cruzamento com Brent/dólar e SCD Tipo 2 — backlog v2.0

11. Checklist Final antes de Publicar

- ☐ Pipeline roda de ponta a ponta com um comando
- ☐ Todos os testes de qualidade passando (dbt test / pytest)
- ☐ README com diagrama, instruções, decisões técnicas e prints
- ☐ Nenhuma credencial ou .env commitado no repositório
- ☐ Insights reais preenchidos na seção de resultados
- ☐ CI verde no GitHub Actions
- ☐ Repositório com descrição, topics e licença no GitHub